

Hanna Kaimo – Saku Ihalainen – Elyas Addawe

LUOTTORISKIT

Tehtävä n:o 5

Metropolia Ammattikorkeakoulu
Tieto- ja viestintätekniikka
Datan käsitteily ja koneoppiminen
28.3.2022

1 Tavoitteet

Analysoitava luottoriski- aineisto sisältää 20 selittävää muuttujaa ja viimeinen muuttuja ilmentää, onko henkilön luottoriski matala vai korkea. Selvitämme tämän koko aineiston perusteella, miten hyvin päätöspuu soveltuu henkilön luottoriskin ennustamiseen. Selvityksen perustamme ositus- validointiin, jossa osa aineistosta on testi- joukossa. Tutkimme myös kokeellisesti, miten päätöspuun koko ja muut parametrit vaikuttavat päätöspuun luokittelu- kykyyn. Painotamme osassa kokeista virhe- tilannetta, jossa henkilö saa luoton, vaikka riski rahojen takaisin saamiseen on korkea.

2 Data

Aineiston lähde: Lichman, M. (2013). UCI Machine Learning Repository [<http://archive.ics.uci.edu/ml>]. Irvine, CA: Univ. of California, School of Information and Computer Science

Attribuutit:

Status Of Checking Account: nominaali- muuttuja, vaihteluväli datassa A11- A13

Duration: numeerinen muuttuja, vaihteluväli datassa 4- 72

Credit History: nominaali- muuttuja, vaihteluväli datassa A30- A34

Purpose: nominaali- muuttuja, vaihteluväli datassa (A40- A49) + A410

Amount: numeerinen muuttuja, vaihteluväli datassa 250- 18 484

Bonds: nominaali- muuttuja, vaihteluväli datassa A61- A65

Employment: nominaali- muuttuja, vaihteluväli datassa A71- A75

Installment Rate: numeerinen muuttuja, vaihteluväli datassa 1- 4

Personal Status: nominaali- muuttuja, vaihteluväli datassa A91- A93

Quarantors: nominaali- muuttuja, attribuutin arvo A101, A102 tai A103

Present Residence: numeerinen muuttuja, vaihteluväli 1- 4

Property: nominaali- muuttuja, vaihteluväli A101- A104

Age: numeerinen muuttuja, vaihteluväli 19- 75

Plans: nominaali- muuttuja, attribuutin arvo A141, A142 ta A143

Housing Type: nominaali- muuttuja, attribuutin arvo A151, A152 tai A153

Credits: numeerinen muuttuja, vaihteluväli 1- 4

Job: nominaali- muuttuja, vaihteluväli A171- A174

Liability Of People: numeerinen muuttuja, attribuutin arvo joko 1 tai 2

Telephone: nominaali- muuttuja, attribuutin arvo joko A191= ei ole tai A192= on

Foreign Worker Or Not: nominaali- muuttuja, attribuutin arvo joko A201= on tai A202= ei ole

Luottoluokitus: numeerinen muuttuja, attribuutin arvo on joko 1= alhainen riski luoton antamiseen tai 2= korkea riski luoton antamiseen

Datan koko on 1000 attribuuttia. Datassa ei ole puuttuvia tai poikkeavia arvoja.

3 Daten valmistelu

Tutustuimme german.doc- tiedostoon. Lisäsimme pilkut aineiston attribuuttien välille välijöntien sijaan Notepad++ etsi- korvaa- toiminnolla, jolloin attribuutit erottuvat toisistaan. Lisäsimme otsikot attribuuteille, koska Wekassa attribuutit on listattu otsikon mukaan. Muutimme german.data- tiedostomuodon ensin german.csv-tiedostomuodaksi ja sen konverterilla german.arff- tiedostomuodoksi, joka on hyvä tiedostomuoto Wekaakin varten. Tarkistimme Wekassa, että datassa ei ole poikkeavia arvoja. Kävimme datan läpi vielä silmämääräisestikin, koska se oli mahdollista datan koon ollessa suhteellisen pieni. Vaihdoinne luottoluokitus- attribuutin muodon numeerisesta nominaaliksi ja numero- arvoja sisältävien attribuuttien muodon numeeriseksi.

4 Mallinnus

Käytimme datan analysoinnissa kustannuspohjaista algoritmia. Wekassa tämä algoritmi löytyy nimellä Cost Sensitive Classifier. Opetusjoukon tarkkuus on 100 %. Siinä ei ole virheitä.

```

Correctly Classified Instances      1000      100      %
Incorrectly Classified Instances     0         0      %
Kappa statistic                   1
Total Cost                       0
Average Cost                     0
Mean absolute error              0.001
Root mean squared error          0.001
Relative absolute error           0.2375 %
Root relative squared error      0.2178 %
Total Number of Instances        1000

==== Detailed Accuracy By Class ====

      TP Rate   FP Rate   Precision   Recall   F-Measure   MCC    ROC Area   PRC Area   Class
      1,000     0,000     1,000     1,000     1,000     1,000   1,000     1,000     1
      1,000     0,000     1,000     1,000     1,000     1,000   1,000     1,000     2
Weighted Avg.      1,000     0,000     1,000     1,000     1,000     1,000   1,000     1,000

==== Confusion Matrix ====

      a     b  <-- classified as
 700   0 |   a = 1
  0 300 |   b = 2

```

Muutimme Test option arvoksi Split Validation, Percentage Split (66 %, 2/3 opetusjoukkoksi ja 1/3 testijoukkoksi) ja parametreiksi laitoimme siis J48- päätöspuun ja kustannusmatriisiin. Siemen- arvo on 21, attribuuttien määrä datassa. Tämän algoritmin idea on se, että toisin kuin esim. KNN- algoritmissa, tässä algoritmissa on mahdollista painottaa jonkin attribuutin painoarvoa. Ja siksi käytämme sitä. Pyrimme minimoimaan virheistä syntyneet kustannukset. Nyt katsomme, mitä tuloksia saamme ilman painotuksia eri kokoisilla päätöspuilla ja katsomme, mitä tapahtuu, kun painotamme sitä, että henkilölle annetaan luotto, vaikka riski luoton antamiseen henkilölle on korkea. Kustannus on tällöin viisinkertainen. Kustannusmatriisi on silloin tämän näköinen:

0 1

5 0

Kun se ilman painotusta on;


0 1

1 0

Päätöspuun kokoa saa siis muuttua muuttamalla Confidence Factory- parametria.

Perustamme tuloksemme testi- joukolle.

Huomaamme heti, että Wekan oletusarvo 0.25 Confidence Factory-parametrille tekee aivan liian ison päätöspuun. Vaihdamme ensimmäiseksi arvoksi 0.1, emme painota aluksi kumpaakaan arvoa ja saamme tämän näköisen päätöspuun:



Tämän testijoukon tarkkuus on 72.65 %. Päätöspuun kokoa vaihtelemalla huomaamme, että päätöspuun koko ei kauhean paljon vaikuta testijoukon tarkkuuteen. Esimerkiksi Confidence Factory arvo 0.02 antaa 73.5 % tarkkuuden ja Confidence Factoryn arvo 0.5: 71.2 %. Puun tasapainoisempi kyllä monilla muilla arvoilla kuin kuvassa näkyvä puu.

Kokeilemme tehdä päätöspuun Confidence Factory arvolla 0.1 ja vaihdamme luoton antamisen painoarvoksi 5. Päätönpuusta tulee liian iso tulkittavaksi ainakin meidän resursseilla (epäselvä). Ja mikä tärkeää asia selviää: testijoukon tarkkuuskin on vain 57 %. Matrix:sta näkee myös, että nyt paljon arvoja 1 on luokiteltu 2:ksi.

```

==== Confusion Matrix ====

    a   b   <- classified as
112 138 |   a = 1
     8   82 |   b = 2
  
```


Vaikka vaihdamme Confidence Factoryn arvoa, jää testijoukon tarkkuus alhaiseksi, kun painotamme luoton antoa arvolla 5. Ja matriisin arvot ovat näyttämämmeksi kaltaisia.

```
== Summary ==
Correctly Classified Instances      196          57.6471 %
Incorrectly Classified Instances    144          42.3529 %
Kappa statistic                      0.2523
Total Cost                           144
Average Cost                         0.4235
Mean absolute error                  0.4263
Root mean squared error              0.5419
Relative absolute error              102.7906 %
Root relative squared error         121.909 %
Total Number of Instances            340

== Detailed Accuracy By Class ==
           TP Rate   FP Rate   Precision   Recall   F-Measure   MCC     ROC Area   PRC Area   Class
           0,456     0,089     0,934     0,456     0,613     0,338     0,694     0,848     1
           0,911     0,544     0,376     0,911     0,532     0,338     0,694     0,387     2
Weighted Avg.     0,576     0,209     0,787     0,576     0,592     0,338     0,694     0,726

== Confusion Matrix ==
      a   b   <-- classified as
114 136 |   a = 1
   8   82 |   b = 2
```

Päätöspuu luoton antamisen virheellisyyden painotuksella 5. Confidence Factoryn arvolla 0.01:



5 Arviointi

Testi- joukosta laskettu kustannus oli n. 100 ilman arvon 1 painotusta ja kun painotimme luoton antamista virheellisesti arvolla 5, testi- joukosta laskettu kustannus oli paljon korkeampi, pääsääntöisesti yli 140. Emme saaneet niin tarkkoja tuloksia kuin esimerkiksi harjoituksessa 4. Arvon 1 Painotus arvolla 5 ei anna myöskään kauhean tarkkoja tuloksia. Arvojen 1 luokittelu virheellisesti arvoksi 2 nousi, jos painotus oli 5 arvolle 1. Kokeilimme mielenkiinnosta vaihtaa painotuksen arvoa esim. arvoon 2 ja arvoon 3. Tarkkuus nousi hieman ja väärin Matrixissa luokitellut arvot vähennivät aika paljon ja jakautuivat tasaisemmin. Päätöspuu oli myös epätasainen monilla arvoilla, siis vasen tai oikea puoli oli dramaattisesti isompi. Tottakai kun painotimme arvoa 1, arvon 2 luokittelujen määrä virheellisesti arvoksi 1 laski todella paljon.

6 Täytäntöönpano

Päätöspuu ei sovelli hyvin henkilön luottoriskin ennustamiseen. Emme saaneet testijoukon tarkkuutta nousemaan edes yli 80 %. Jos painotimme luoton antamista potentiaaliselle maksukyvyttömälle henkilölle tilanne vain paheni. Tarkkuus jäi todella alhaiseksi. Kun tarkastelemme päätöspuita mielestäni myös niiden rakenne on sellainen, että siinä esimerkiksi epäolennaisia attribuutteja on korkealla (lähellä puun juurta), mutta tämä on vain mutu- tuntuma, koska juuri opimme tekemään ylipäätään päätöspuita Wekalla. Toimenpidesuositus olisi etsiä vaihtoehtoinen luottoriskien ennustustapa tai ehkä muokata dataa, tarkasteltavia attribuutteja tms.